

# Framework para Coleta e Inferência de Estados Emocionais de Alunos Baseado em Reconhecimento de Expressões Faciais

Anderson Cruz<sup>1</sup>, Juan Colonna<sup>1</sup>, Gabriel Leitão<sup>1</sup>, Edson Silva<sup>1</sup>,  
Raimundo Barreto<sup>1</sup>, Tiago Thompsen Primo<sup>2</sup>

<sup>1</sup>Instituto de Computação – Universidade Federal do Amazonas (UFAM) –  
Manaus, AM – Brazil

<sup>2</sup>CDTec – Universidade Federal de Pelotas (UFPEL) - Rio Grande do Sul - Brazil

{aac, juancolonna, gabriel.leitao, rbarreto}@icomp.ufam.edu.br,  
edsonaraujo@ufam.edu.br, tiagoprime@gmail.com

**Abstract.** *In this article, we propose a framework to detect emotional states from facial expressions of the students in the context of digital learning platforms. We analyzed and discussed the use of correlation and entropy between student's emotional states and their performance during a multiple choice assessment. We conducted an experiment with 27 students, which were subject to an evaluation with 40 questions. During our analysis, we correlated the emotional states: neutrality, sadness, happiness, anger, disgust, fear, contempt, and surprise, with the performance achieved by each student. Finally, we found that the questions that caused greater variability of emotions in the students also had the highest proportion of correct answers.*

**Resumo.** *Neste artigo, propomos um framework para detectar estados emocionais de alunos baseado em reconhecimento de expressões faciais no contexto das plataformas digitais. Analisamos e discutimos o uso de correlação e entropia entre os estados emocionais dos estudantes e o desempenho durante uma avaliação de múltipla escolha. Realizamos um experimento com 27 estudantes e elaboramos um teste composto de 40 perguntas. Na análise, correlacionamos os estados emocionais de neutralidade, tristeza, felicidade, raiva, desgosto, medo, desprezo e surpresa com o desempenho no teste. Concluímos que as questões que ocorreram maior variabilidade das emoções tinham também as maiores proporções de acertos.*

## 1. Introdução

Diversos psicólogos e pedagogos acreditam que o processo de cognição não pode ser separado do afetivo. Vygotsky (1962) propõe uma união entre os processos intelectuais, evolutivos e afetivos, e que a sua separação gera uma série de lacunas. Piaget (1989) afirma que a afetividade alimenta a atividade intelectual, isto é, não há processo cognitivo sem afetivo. Izard (1984) concluiu que emoções negativas no estudante prejudicam o seu desempenho em tarefas cognitivas e emoções positivas possuem um efeito oposto.

A integração de um reconhecedor de emoção com Sistemas Tutores Inteligentes (STI) pode ser capaz de auxiliar os grandes desafios da área de informática na educação, como viabilizar recomendações mais eficazes, no que diz respeito a utilizar um determinado estado emocional do estudante para fornecer uma recomendação mais inteligente, personalizada e propícia para aquele momento (Jaques, 2012).

Neste contexto, este artigo tem como objetivo: (i) propor uma arquitetura de detecção automática de emoções para ambientes educacionais digitais por meio de reconhecimento automático de expressões faciais, utilizando processamento digital de imagens, de modo a tornar possível a obtenção de dados emocionais dos alunos durante o processo de aprendizagem, e (ii) analisar por meio de estatística descritiva um estudo de caso com dados obtidos a partir desta arquitetura. Esta análise pretende investigar e medir correlações entre as emoções e o desempenho obtido nas questões, levantando hipóteses relevantes sobre a relação entre os estados emocionais e o desempenho, o qual é relevante para sistemas de recomendações, tutores inteligentes e heurísticas em geral, que se interagem de forma dinâmica com as necessidades de aprendizado de cada aluno.

Este trabalho está dividido nas seguintes seções. A Seção 2 apresenta a fundamentação teórica, incluindo as definições dos métodos de estatística descritiva utilizados e o reconhecimento de emoção por expressão facial. A Seção 3 analisa os trabalhos relacionados. A Seção 4 descreve o método proposto. A Seção 5 detalha a metodologia experimental utilizada para a coleta de dados e a execução de um estudo de caso. A Seção 6 discute os resultados obtidos enquanto a Seção 7 enfatiza as considerações finais acerca deste trabalho, assim como os trabalhos futuros.

## **2. Fundamentação Teórica**

Este trabalho se apoia na importância e na necessidade da investigação de estados emocionais durante o processo de aprendizagem. Muitos pedagogos e psicólogos da educação avaliaram como o estado emocional influencia no rendimento do estudante durante o processo educacional. Goleman (1995) descreve que alunos deprimidos, mal-humorados e ansiosos encontram maiores dificuldades em aprender. Piaget (1989) enfatiza que boa parte dos alunos que apresentam dificuldades em matemática se deve a um bloqueio afetivo. Para Vygotsky (1962), a motivação é um fator fundamental para aprendizagem, pois, enquanto os estudantes estiverem motivados, eles buscam as soluções de seus problemas e a satisfação de suas necessidades, isto é, a motivação que impulsiona as necessidades, interesses, desejos e atitudes particulares das pessoas.

### **2.1. Reconhecimento de emoção por expressões faciais**

Darwin (1965) verificou que fenômenos emocionais presentes em expressões faciais, podem ser encontrados em diversas culturas. Adicionalmente, Ekman (1994) concluiu que existe um conjunto de expressões faciais que são universais, ou seja, que

representam a mesma emoção em diferentes culturas. Tanto Ekman (1994) quanto Izard (1984) acreditam na existência de um grupo de emoções básicas (raiva, felicidade, tristeza, desprezo, medo e surpresa) que possuem a mesma expressão facial independente da cultura do indivíduo.

Para dotar computadores com a capacidade de reconhecer emoção é muito comum o emprego de técnicas de aprendizagem de máquina, que é um ramo da inteligência artificial, onde máquinas aprendem a partir de uma experiência. Uma definição de aprendizagem de máquina foi dada por Alpaydin (2010): “Aprendizagem de máquina é a programação de computadores para otimizar um critério de desempenho usando dados de exemplo ou experiência passada”. Existe um modelo definido com alguns parâmetros, e a ação de aprender é a partir de uma execução de um programa de computador que otimiza os parâmetros do modelo usando os dados de treinamento ou experiência passada. O modelo pode ser *preditivo* para fazer previsões do futuro, ou *descritivo* para obter conhecimento dos dados realizando a classificação, ou ambos.

O reconhecimento de emoção por expressão facial tem sido amplamente explorado, não somente por, em tese, uma expressão facial representar a mesma emoção independente da cultura, mas também por não ser um método invasivo de captura de dados. Neste caso, o reconhecimento de emoção é também favorecido pelos avanços nas câmeras fotográficas e a sua popularidade presente em variados dispositivos, como também, no aprimoramento e surgimento de técnicas altamente eficazes de classificação de imagens como o aprendizado profundo em redes neurais artificiais.

## **2.2. Entropia e Correlação**

A entropia pode ser interpretada como uma medida de dispersão de uma distribuição de probabilidades. Possui a sua origem na teoria da informação e seu resultado implica que quanto maior a entropia, maior a uniformidade da distribuição dos dados. Em nosso caso, utilizamos a entropia para quantificar a dispersão do vetor de probabilidades, que representa o conjunto das emoções detectadas pelo método de reconhecimento facial, para cada aluno sendo agrupado por questão pertencente na avaliação.

O coeficiente de Pearson mede o grau de correlação (força e direção) entre um par de variáveis aleatórias. Assim, quando o resultado da correlação se aproxima de 0, não há qualquer correlação entre duas variáveis aleatórias. Quando o resultado se aproxima de 1, as duas variáveis possuem forte correlação e na mesma direção, isto é, quando uma cresce, a outra cresce também. Quando o resultado se aproxima de -1, as duas variáveis aleatórias são fortemente correlacionadas, porém, em direções opostas. Neste trabalho, a correlação é utilizada para descobrir se há relação entre as emoções detectadas e os valores de entropia com as proporções de acertos e nível de dificuldade de cada questão.

## **3. Trabalhos Relacionados**

Pesquisas na área da afetividade tradicionalmente eram conduzidas por filósofos, pedagogos e psicólogos, embasados em um conjunto pequeno de teorias das emoções. Com o advento da Computação Afetiva (CA), diversos autores, como Turkle (1984),

começaram a introduzir os computadores para a obtenção e interpretação dos dados. Nesse sentido, o trabalho de Calvo e D'Mello (2010), cujo foco é a detecção de afetos, expõe uma revisão dos fundamentos da natureza multidisciplinar que incorpora os sistemas de Computação Afetiva e como as teorias psicológicas de emoção afetam as pesquisas, métodos, resultados e suas interpretações.

O estudo de Lin (2017) propôs um modelo de reconhecimento de emoção que inclui três fases: extração de atributos, seleção de subconjuntos de características e classificação de emoção. O objetivo foi identificar a compreensão dos alunos ao longo de um curso de ensino a distância por meio da extração de imagens. O trabalho mostrou que a identificação da compreensão do aluno, com base na expressão facial em cursos de ensino à distância, pode ajudar os instrutores no entendimento da compreensão dos alunos e na adequação de seus materiais de acordo com o nível dos estudantes. O modelo de reconhecimento de emoção é formado por IMCFS (*Immune Memory Clone Feature Selection*) e SVM (*Support Vector Machine*), como algoritmo de seleção de atributos e classificação, para inferir um estado de emoção booleana, podendo ser 0 ou 1, referindo-se ao estado de não compreensão e compreensão, respectivamente.

Com intuito de detectar o estado emocional durante uma aula e oferecer informações aos educadores sobre os estados emocionais de alunos, o estudo de Ayvaz e Gürüler (2017) explora o uso de SVM obtendo acurácia de 97,15%. Entretanto, esse resultado tão expressivo pode ter sido alcançado por terem realizado o treinamento e teste com os mesmos 12 participantes da pesquisa, fazendo com que a detecção fosse muito boa para aqueles 12 participantes e, provavelmente, ruim para participantes desconhecidos. Neste trabalho, os dados de treinamento foram extraídos por meio de vídeos em 30 frames por segundo, considerando atributos relacionados a expressão facial obtida mediante ao processamento digital de imagem e acrescentando o atributo que identifica o sexo, sendo considerado fator relevante no momento da classificação. Os estados emocionais utilizados para classificação foram: felicidade, tristeza, raiva, surpresa, medo, desprezo e neutralidade. Algumas dificuldades foram identificadas pelos autores, como a distância do aluno e seu ângulo de visão em relação a câmera e a quantidade de luz ambiente.

Esses trabalhos demonstram a viabilidade para reconhecimento de emoção por meio da expressão facial e seus possíveis benefícios para educação, de forma a proporcionar uma dinâmica no ensino-aprendizagem individualizada e focada na união dos processos intelectuais apontada por Vygotsky (1962). É necessário o emprego de modelos que associam o estado afetivo com o cognitivo para fazer inferências mais precisas, no que diz respeito ao desempenho e a personalização de conteúdo individualizada durante o processo de aprendizagem. Este trabalho investiga o

reconhecimento de emoção, de forma não intrusiva, e analisa a correlação entre as diversas emoções detectadas com o desempenho e o nível de dificuldade das questões.

#### **4. Método Proposto**

A arquitetura proposta na Figura 1 é formada pelos seguintes componentes: (i) uma plataforma educacional digital executada, por exemplo, em um *tablet* com câmera frontal que possibilite a coleta de imagens das expressões faciais e das atividades dos alunos, relacionadas com a seleção das respostas e a navegação entre os diferentes objetos de aprendizagem; (ii) um classificador de emoções que recebe como entrada as imagens das expressões faciais e retorna um vetor com as probabilidades *a posteriori* das seguintes emoções: neutralidade, surpresa, felicidade, tristeza, desprezo, raiva, medo e desgosto; e (iii) um conjunto de métodos de estatística descritiva para realizar diversas análises úteis para: inferências, heurísticas, sistemas de recomendações, tutores inteligentes e inclusive para auxiliar o professor na tomada de decisões referentes às dificuldades de aprendizagem de cada aluno. A arquitetura proposta pode ser usada em tempo real, tanto em ambientes presenciais como à distância, possibilitando o cruzamento dos estados emocionais com a interação na plataforma.

##### **4.1. Plataforma educacional**

A plataforma educacional deve possuir um módulo coletor de dados que armazene continuamente os eventos da interação do estudante, tais como, a seleção das questões e suas respectivas respostas, e a identificação de todos os itens presentes na interface como botões, caixa de texto, opções de seleções e outros, assim como, a captura contínua da expressão facial do estudante.

Estes dados são armazenados para tornar possível diferentes análises, tais como: qual foi a emoção predominante na questão que os alunos mais erraram? Na questão que houve mais troca de respostas qual foi a emoção predominante? Qual foi a emoção predominante no grupo de alunos que mais erraram as questões? Quais são as emoções causadas pela variação da dificuldade das questões? Isto pode ser um caminho para inferir a confusão via expressão facial, onde D'Mello (2013), em alguns estudos de casos, concluiu que a confusão, tédio, curiosidade, engajamento, frustração e satisfação ocorrem cinco vezes mais do que as emoções básicas no âmbito educacional.

##### **4.2. Classificador de emoção**

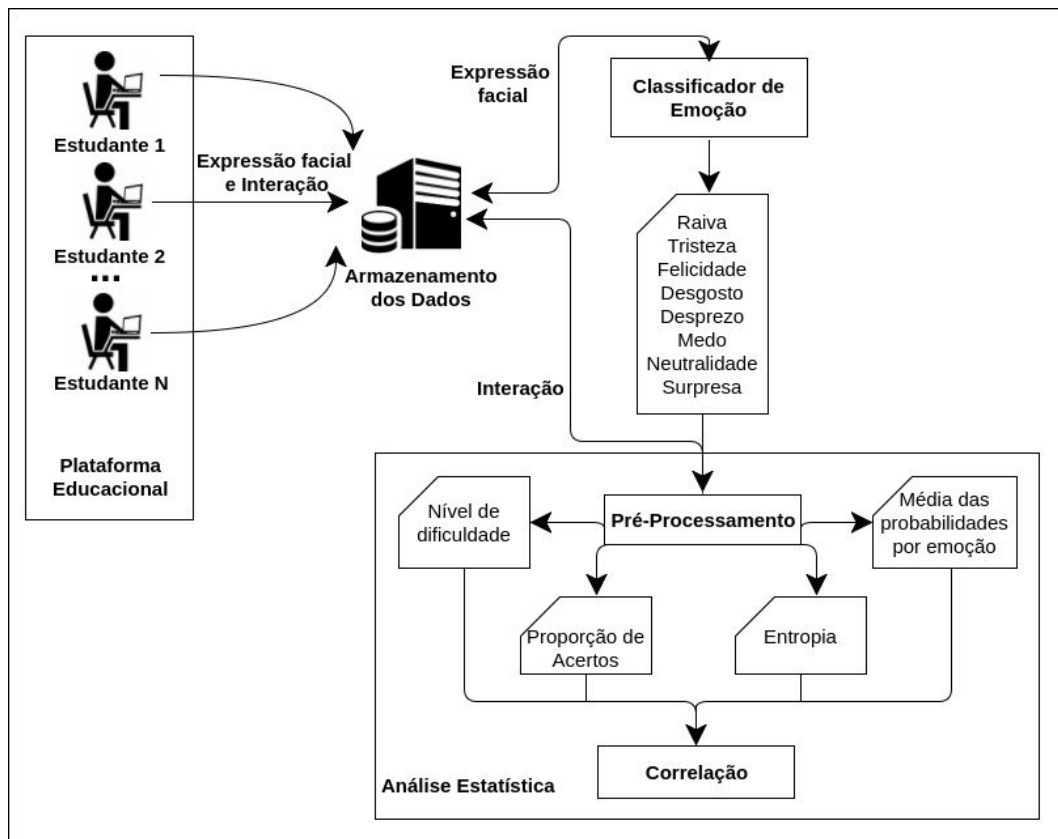
O classificador de emoção tem a função de identificar nas imagens as expressões faciais de um estudante e atribuir um rótulo a cada imagem. Estes rótulos podem ser: neutralidade, raiva, felicidade, tristeza, desgosto, desprezo, medo e surpresa, como mencionado por Ekman (1994) e Izard (1984), que são as emoções básicas capazes de ser reconhecidas dada uma expressão facial.

O classificador utilizado está descrito na Seção 5.1, e usufrui de técnicas de aprendizagem de máquina, mais especificamente de aprendizagem profunda em redes neurais pela arquitetura *Convolutional Neural Network* (CNN), que tem sido o estado da arte para este fim.

A saída do classificador de emoção para cada imagem recebida é um vetor de probabilidades que contém a probabilidade de cada emoção detectada na imagem *i.e.*:  $P = \{p_1, p_2, \dots, p_n\}$ , onde  $p_n$  representa a probabilidade *a posteriori* da detecção da  $n$ -ésima emoção. Uma propriedade é que a soma das probabilidades é igual a 1, e que a maior probabilidade presente no vetor corresponde ao rótulo final da emoção detectada na imagem, ou seja, a sua classificação *e.g.*:  $emoção = \max(P)$ .

### 4.3. Análise Estatística

Este componente contém outros subcomponentes que realizam análises acerca do desempenho e das emoções do estudante por meio da correlação de Pearson. Todos os subcomponentes recebem como entrada tanto os cliques de interação do estudante com a plataforma, como as classificações das expressões faciais. Desta forma, são recuperadas todas as instâncias necessárias para a realização do cruzamento da interação da plataforma com a emoção detectada, a fim de obter o coeficiente de correlação.



**Figura 1. Método proposto**

Um pré-processamento dos dados é executado antes da análise, onde é organizada a coleção de dados por questão, isto é, a reunião de todas as instâncias de todos os alunos com respeito a uma determinada questão e, desta forma, são agrupados a interação com a plataforma e os dados das classificações de emoções por questão. O pré-processamento produz as seguintes informações para cada questão:

- a média das probabilidades para cada emoção, incluindo todos os alunos;
- o nível de dificuldade;

- a proporção de acertos, por exemplo, se a metade dos alunos acertaram, então a proporção é 50%; e
- a entropia das emoções, que mede a dispersão das probabilidades das emoções detectadas, isto é, caso em uma questão haja várias emoções diferentes e estejam distribuídas uniformemente, a entropia será maior.

Todos esses dados pré-processados entram no componente de análise estatística, e a sua saída pode ser útil para traçar um perfil emocional do estudante e da turma mediante as correlações identificadas.

## 5. Metodologia Experimental

Um experimento foi realizado com 27 alunos do Ensino Médio de uma escola de tempo integral que farão o Exame Nacional do Ensino Médio (ENEM) 2017. O experimento consistiu em um simulado do exame contendo 40 questões de múltipla escolha.

### 5.1. Planejamento

Adotamos uma plataforma educacional que permite a execução de questionários de múltipla escolha, coleta de cliques efetuados pelo estudante, captura automática de foto via câmera frontal do dispositivo, seja por tablet, smartphone ou notebook. Os assuntos escolhidos foram: matemática, língua portuguesa, química, raciocínio lógico, geografia e história. O simulado teve duração de duas horas e cada questão possuía dois níveis de dificuldade (fácil ou difícil), além de ter cinco respostas alternativas.

Para o componente classificador, selecionamos a API da *Microsoft Cognitives Services*, justamente por classificar bem emoções como neutralidade, felicidade e tristeza. Acreditamos que, no contexto da educação, uma emoção bastante comum é a neutralidade, pelo fato da expressão facial do estado de concentração se assemelhar bastante com a expressão facial de neutralidade reconhecida por esta API. Constatamos que estudantes quando estão pensando, estão concentrados, emitindo poucas movimentações intensas e variações de suas expressões faciais, assemelhando-se com a expressão de neutralidade.

### 5.2. Execução

A seleção dos estudantes para participar do experimento ocorreu voluntariamente. O grupo final formado foi heterogêneo, onde 53% consideravam até o momento seu desempenho na escola como bom ou ótimo e, 47% como regular ou ruim; além disso, 30% deles consideravam a sua preparação para o vestibular como boa ou ótima e, 70% como regular ou fraca. Os alunos selecionados são de turmas diferentes.

## 6. Resultados e Discussões

Inicialmente, obtemos os seguintes atributos calculados como os valores médios por questão, utilizando os dados coletados dos vinte e sete alunos: (i) a proporção de acertos; (ii) o nível de dificuldade; (iii) a média das probabilidades para cada emoção detectada; e (iv) a entropia por questão. Assim, obtemos um total de onze atributos (resumidos na Tabela 1), onde cada um deles é representado por uma variável aleatória com quarenta valores.

Posteriormente, aplicamos a correlação de Pearson para analisar se há qualquer grau de correlação entre os pares dos atributos mencionados. A Tabela 1 apresenta a correlação entre a média das probabilidades de cada emoção com o nível de dificuldade e a proporção de acertos. Os principais resultados estão destacados em negrito.

	Nível de Dificuldade	Proporção de Acertos
<b>Tristeza</b>	<b>-0.33</b>	0.27
<b>Neutralidade</b>	<b>0.36</b>	<b>-0.48</b>
<b>Desprezo</b>	-0.15	<b>0.30</b>
Desgosto	-0.13	0.07
Raiva	-0.14	-0.08
Surpresa	0.07	0.24
Medo	-0.06	0.14
<b>Felicidade</b>	-0.14	<b>0.31</b>
<b>Entropia</b>	-0.12	<b>0.36</b>

**Tabela 1. Resultado da correlação de Pearson para cada emoção detectada e a entropia contra os atributos das questões**

Como podemos verificar na Tabela 1, a expressão facial neutra possui uma correlação negativa com a proporção de acertos dos alunos (segunda coluna da Tabela 1). Isto indica que estimular emoções diferentes da neutralidade durante a avaliação favorece o desempenho dos alunos. Um segundo indicativo de que isto ocorre, é dado pela correlação positiva entre o desprezo e a felicidade com a proporção de acertos e, de forma discreta, também ocorre com tristeza, surpresa e medo.

A entropia é calculada a partir do valor das probabilidades das emoções detectadas. Logo, percebemos que quando a neutralidade baixa, a entropia aumenta, o que significa que outras emoções estão sendo detectadas com maior probabilidade, ocorrendo a dispersão dos estados emocionais. Portanto, o fato de existir uma correlação positiva entre o aumento da entropia e a proporção de acertos reforça a observação constatada no parágrafo anterior. Adicionalmente, descobrimos que a emoção mais frequente foi a neutralidade, devido aos alunos passarem a maior parte do tempo concentrados analisando as questões para a busca de soluções. Assim, quando o nível de dificuldade da questão aumenta, a neutralidade também aumenta, isto pode ser um indício de que questões mais difíceis tem tendências de exigir maiores níveis de concentração do estudante.



Podemos considerar a hipótese de que, quando o estudante está respondendo uma questão, ao selecionar uma resposta, o mesmo tem uma percepção se acertou ou errou e, nesse momento, há possibilidade de emitir emoções positivas como felicidade e surpresa, ou emoções negativas como tristeza ou desprezo. Portanto, há uma variação dos estados emocionais durante o tempo de resposta de cada questão que deve ser considerado como um problema de mudança de estados. Este resultado é reforçado por questões que ocasionaram maior entropia, ou seja, quanto maior a dispersão das emoções, maior é o índice de proporções de acertos.

A emoção desprezo aumenta a medida que as questões têm maiores proporções de acertos, isto pode ser explicado, pela mudança de estados durante o tempo de resposta de cada questão ou pelo fato da expressão facial de desprezo se assemelhar com a expressão facial de felicidade. Neste caso, é bem provável estar ocorrendo confusão por parte do classificador em diferenciar felicidade e desprezo.

## 7. Considerações Finais

Neste trabalho, propomos uma arquitetura de reconhecimento de emoções de alunos por meio de sua expressão facial para plataformas educacionais, a partir da qual realizou-se um estudo de caso com a coleta de dados reais de estados emocionais obtidos por meio da própria arquitetura. Como resultado principal apontamos que as questões onde ocorreram diferentes emoções, são as questões onde há maiores proporções de acertos.

Tanto a arquitetura para o reconhecimento de estados emocionais, como a realização de análises de estados emocionais de estudantes, são úteis para a implementação de tutores inteligentes e sistemas de recomendações que possam fornecer personalização mais precisa do conteúdo para cada aluno levando em consideração seus estados emocionais. É importante identificar os casos diferentes da expressão neutra, justamente por serem menos frequentes podendo indicar alguma oportunidade de um tutor inteligente atuar.

Como trabalho futuro, pretendemos investigar a mudança temporal dos estados emocionais do estudante, mediante a estímulos produzidos por diferentes objetos de aprendizagem durante uma aula. Também, a implementação de uma heurística que considera o estado emocional do estudante para fornecer ajuda sob demanda com a intenção de aumentar o engajamento e o desempenho durante uma aula.

Finalmente, percebe-se que o *framework* para classificação automática de emoções a partir de imagens necessita de um maior volume de dados, para reduzir eventuais erros de classificação, e permitir a classificação de novos tipos de emoções. Portanto, está nos nossos planos investigar alternativas para amenizar erros de classificação e melhorar a acurácia do *framework*.

## 8. Agradecimentos

Esta pesquisa foi parcialmente financiada por intermédio de um projeto de P&D com a Samsung Eletrônica da Amazônia Ltda. Os autores Anderson Cruz e Tiago Thompsen Primo são bolsistas CAPES, sendo o último, modalidade PNPd-UFPEL, e agradecem pelo apoio financeiro e concessão de bolsa.

## 9. Referências

- ALPAYDIN, Ethem. Introduction to machine learning. MIT press, 2014.
- AYVAZ, U.; GÜRÜLER, H. Real-Time Detection of Students' Emotional States in the Classroom. 25th Signal Processing and Communications Applications Conference (SIU), IEEE. Antalya, Turkey, 2017, pp. 1-4.
- CALVO, Rafael A.; D'MELLO, Sidney. Affect detection: An interdisciplinary review of models, methods, and their applications. IEEE Transactions on affective computing, v. 1, n. 1, p. 18-37, 2010.
- D'MELLO, Sidney; CALVO, Rafael A. Beyond the basic emotions: what should affective computing compute?. In: CHI'13 Extended Abstracts on Human Factors in Computing Systems. ACM, 2013. p. 2287-2294.
- DARWIN, C. R. The Expression of emotions in man and animals. London: Murray, 1965.
- EKMAN, P. All Emotions are Basic. In: EKMAN, P.; DAVIDSON, R. (Ed.). The Nature of Emotion. Oxford: Oxford University Press. p. 15-19. 1994. Learning Systems Group, DECE, University of Sydney. 2009.
- GOLEMAN, D. Emotional Intelligence. New York: Bantam Books, 1995.
- IZARD, C. Emotion-cognition relationships and human development. In: IZARD, C.; KAGAN, J.; ZAJONC, R.B. (Ed.). Emotions, cognition, and behavior. New York: Cambridge University Press. p. 17-37. 1984.
- JAQUES, P. A.; NUNES, M. A.; ISOTANI, S.; BITTENCOURT, I. Computação Afetiva aplicada à Educação: Dotando Sistemas Tutores Inteligentes de Habilidades Sociais. In: CSBC 2012 - Desafie, 2012, Curitiba. Anais do CSBC, 2012.
- LIN, K. C.; HUANG, T. C.; HUNG, J. C.; YEN, N. Y.; CHEN, S. J. "Facial emotion recognition towards affective computing-based learning", Library Hi Tech, Vol. 31 Issue: 2, pp.294-307, 2017.
- PIAGET, J. Les relations entre l'intelligence et l'affectivité dans le développement de l'enfant. In : RIMÉ, B.; SCHERER, K. (Ed.). Les Émotions. Paris: Delachaux et Niestlé, 1989.
- TURKLE, S. The Second Self: Computers and the Human Spirit. Simon & Schuster, 1984.
- VYGOTSKY, L. Thought and Language. Cambridge, MA: MIT Press, 1962.